

Examen Preguntaa 18

Monserrat de la Garza
A01722979

Colab link:

https://colab.research.google.com/drive/12_KZK-6uccil3dzzSu09al5CDknwSHWc?usp=sharing

Grok: <https://grok.com/chat/1f242f32-1cc4-4f16-a025-ac42f2b285f4>

Github Link: <https://github.com/A01722979/pregunta-18-examen.git>

En base a lo que se hizo en el colab, podemos ver que Log M1, no es estacionaria ya que tiene un p value de 0.7811, osea arriba de 0.05, y esta puede que tenga una raiz unitaria, pero se tendrá que diferenciar para hacer el arima ya que no es estacionaria. En las series de diferencia, si tiene un p value menor a 0.05, lo que significa que es estacionaria. Despues de una diferenciacion, las dos series son estacionarias.

El código comienza leyendo un archivo Excel que contiene una variable monetaria denominada MONEY. Esta variable representa probablemente la oferta monetaria M1 en Estados Unidos, observada desde 1951 hasta 1999. A continuación, se calcula su logaritmo natural, lo cual es una práctica estadística habitual en economía para suavizar tendencias exponenciales y reducir la heterocedasticidad (cambios de varianza a lo largo del tiempo).

Visualización inicial

Se realiza un gráfico de la serie logarítmica para observar su comportamiento general. Este gráfico debería mostrar una tendencia creciente, lo cual sugiere que la serie no es estacionaria. La presencia de una tendencia sostenida implica que el valor esperado cambia con el tiempo, lo que viola una de las condiciones básicas de estacionariedad.

Pruebas de estacionariedad

El código aplica dos pruebas formales:

- Dickey-Fuller Aumentada (ADF): evalúa si existe una raíz unitaria (hipótesis nula), lo que indicaría no estacionariedad.

- KPSS: evalúa la hipótesis opuesta (la serie es estacionaria alrededor de una tendencia). Si el estadístico es significativo, se rechaza la estacionariedad.

Esto es importante porque usar ambas pruebas da un diagnóstico más completo. Si ADF indica no estacionaria (p-valor alto) y KPSS también rechaza estacionariedad, entonces hay fuerte evidencia de que se requiere transformación adicional de la serie.

Evaluación gráfica de componentes autorregresivos y de media móvil

Si la serie no pasa las pruebas de estacionariedad, el código la diferencia de forma iterativa: Este proceso resta cada valor con el anterior eliminando la tendencia lineal. El código diferencia hasta un máximo de 2 veces ($d \leq 2$), lo cual está alineado con la práctica estándar en modelos ARIMA, donde un orden de diferenciación mayor suele no ser necesario ni deseable.

Una vez diferenciada, se repite la prueba ADF para confirmar si la serie ya es estacionaria. Cuando el p-valor es menor a 0.05, se acepta que la serie ha sido transformada correctamente para aplicar ARMA o ARIMA.

Estimación del modelo ARIMA

Con la serie estacionaria, se evalúan los gráficos de autocorrelación (ACF) y autocorrelación parcial (PACF) para sugerir los valores de p (autoregresivo) y q (media móvil). Si el PACF se corta después del rezago 1 y el ACF también, se sugiere un ARIMA(1,d,1). Esto indica que se encontró un solo rezago significativo tanto en AR como en MA, lo que es común para muchas series macroeconómicas una vez diferenciadas.

Diagnóstico del modelo

6. Estimación del modelo ARIMA

El modelo usa la serie original (time_series), porque internamente ARIMA() aplica las diferencias según el valor d que le proporcionas. Esto es correcto.

La salida del modelo incluye los coeficientes estimados, los errores estándar y los criterios de información como el AIC. Estos ayudan a validar la adecuación del modelo y a compararlo con posibles alternativas.

7. Análisis de los residuos

Después de ajustar el modelo, se extraen y analizan los residuos.

Se grafica la serie de residuos y se aplica la prueba de Ljung-Box para verificar que no haya autocorrelación significativa. Esto es esencial porque un modelo ARIMA bien ajustado debería producir residuos que se comportan como ruido blanco (sin patrones ni memoria).

Si los residuos no son autocorrelacionados (p -valor > 0.05 en Ljung-Box), entonces el modelo es estadísticamente válido.

8. Generación de pronósticos

El modelo se utiliza para hacer una predicción de los próximos 12 periodos, con sus respectivos **intervalos de confianza al 95%**:

La visualización incluye:

- La serie observada (en azul),
- Los valores ajustados (verde),
- El pronóstico (rojo),
- Y la banda de confianza (rosada).

Esto proporciona una herramienta clara para interpretar el comportamiento esperado de la serie, con un rango de incertidumbre incorporado.

Conclusión

Tu código implementa una cadena completa de análisis de series de tiempo con enfoque ARIMA, desde la transformación logarítmica inicial hasta la generación de pronósticos. Aplica pruebas complementarias de estacionariedad, realiza diferenciación controlada, selecciona el modelo mediante análisis gráfico de rezagos, y valida rigurosamente los residuos del modelo. El análisis visual y estadístico está bien respaldado, y el modelo final no solo se ajusta a los datos históricos, sino que también está preparado para proyección futura con un nivel razonable de confianza.

Esta implementación refleja un dominio sólido de la metodología Box-Jenkins y puede aplicarse con facilidad a otras series macroeconómicas con características similares.